

Poređenje MCNN i CSRNet modela za brojanje ljudi u gomili

Uroš Dimitrijević Miloš Kutlešić

Projektni rad iz predmeta Mašinsko učenje

- **Problem:** Automatsko brojanje ljudi na slikama gustih gužvi
- **Zašto ne detekcija objekata?**
 - Jaka okluzija (prekrivanje) u gustim scenama
 - Mali objekti, teško razlikovanje pojedinaca
 - Previše instanci za bounding box pristup (npr. YOLO)
 - I segmentacija pada: ljudi se u gužvi *spajaju* u jednu regiju, maska po osobi je preskupa za anotiranje — dataset daje samo tačke (glave)
- **Rešenje:** Regresija mape gustine (density map)
 - Model uči "koliko je gusta svaka oblast", ne "gde je svaka osoba"
 - Ukupan broj = integral (suma) mape gustine

Teorijska osnova: Mape gustine

- Svaka anotacija (glava) se modeluje Gausovim kernelom:

$$F(x) = \sum_{i=1}^N \delta(x - x_i) * G_{\sigma_i}(x)$$

- **Broj osoba** = $\sum$ vrednosti piksela mape gustine
- Fiksna $\sigma = 15$ (kontrolisano poređenje) vs. adaptivna σ (u daljem radu)
- Prednost: Model uči distribuciju, robustan na okluzije



Slika → anotacije → mapa gustine

MCNN (Zhang et al., 2016)

- Multi-column CNN
- Paralelne grane sa različitim veličinama filtera (5x5, 7x7, 9x9)
- Spajanje mapa na kraju
- 64K parametara
- Učenje od nule (from scratch)

CSRNet (Li et al., 2018)

- Duboka arhitektura sa dilated konvolucijama
- Frontend: VGG16 (pretrained na ImageNet)
- Backend: Dilated konvolucije (veće receptivno polje bez downsampling-a)
- 16M parametara

Hipoteza: Duboka dilated arhitektura (CSRNet) trebala bi da nadmaši multi-column pristup (MCNN) na gustim scenama.

- **Dataset:** ShanghaiTech Part A
 - 300 trening slika, 182 test slike
 - Do 3000 ljudi po slici (visoka gustina)
- **Trening:**
 - Optimizator: SGD sa momentumom 0.95
 - Loss: MSE (pixel-wise) na mapi gustine
 - 50 epoha, batch size 4, seed 42
 - Bez augmentacije (kontrolisano poređenje modela)
- **Metrike:** MAE (Mean Absolute Error), RMSE (Root Mean Squared Error)
- **Konvencija:** Broj ljudi = integral mape gustine

Rezultati: Poređenje na test skupu


Model	Test MAE	Test RMSE	Parametri	Najbolja epoha
MCNN	315.23	429.16	64,385	50
CSRNet	217.13	342.66	16,263,489	34

Rezultat: CSRNet je signifikantno bolji:

- MAE 31% niži (bolji)
- RMSE 20% niži (manja varijansa greške)
- Potvrđena hipoteza o superiornosti dubokih dilated arhitektura

Rezultati: Dinamika treniranja

Training dynamics: MCNN vs CSRNet on ShanghaiTech Part A (50 epochs)



Slika: Krive greške tokom treniranja (train vs validation MAE)

Analiza:

- CSRNet (pretrained VGG): Brza konvergencija, ali **overfitting** posle epohe 34 (val MAE raste, train MAE opada)
- MCNN (from scratch): Sporiji konvergencija, stabilniji do kraja, ali na višem nivou greške^{7/1}

Analiza: Razlika u odnosu na originalne radove

Model	Naš rezultat		Originalni paper	
	MAE	RMSE	MAE	RMSE
MCNN	315	429	~110	~173
CSRNet	217	343	~68	~106

Razlozi odstupanja (sistematski, ne utiču na poređenje):

- Nema augmentacije podataka (random crops, flips)
- Nema learning rate scheduling
- Fiksna σ (umesto adaptivne)
- Manji broj epoha (50 vs. više stotina)

Važno: Relativni odnos je isti kao u literaturi (CSRNet < MCNN).

- **CSRNet superiorniji** od MCNN za brojanje u gustim gužvama na ShanghaiTech Part A
- Tradeoff kapaciteta i veličine skupa podataka:
 - Veliki model (CSRNet, 16M) brže uči ali overfituje na malom datasetu (300 slika)
 - Mali model (MCNN, 64K) sporiji ali stabilniji
- Validnost metodologije: Poređenje pod identičnim uslovima eliminiše uticaj pipeline-a
- **Budući rad:**
 - Augmentacija podataka (kritično za CSRNet)
 - Adaptivna σ za mapu gustine
 - Learning rate scheduling i duži trening

Hvala na pažnji!