

Poređenje MCNN i CSRNet modela za brojanje ljudi u gužvi

Uroš Dimitrijević Miloš Kutlešić

Projektni rad iz predmeta Mašinsko učenje

- **Problem:** Automatsko brojanje ljudi na slikama gustih gužvi
- **Zašto ne detekcija objekata?**
 - Jaka okluzija (prekrivanje) u gustim scenama
 - Mali objekti, teško razlikovanje pojedinaca
 - Previše instanci za bounding box pristup (npr. YOLO)
 - Segmentacija instanci takođe nepovoljna: ljudi se u gužvi *spajaju* u jednu regiju, maska po osobi je preskupa za anotiranje — dataset daje samo tačke (glave)
- **Rešenje:** Regresija mape gustine (density map)
 - Model uči "koliko je gusta svaka oblast", ne "gde je svaka osoba"
 - Ukupan broj = integral (suma) mape gustine

Teorijska osnova: Mape gustine

- Svaka anotacija (glava) se modeluje Gausovim kernelom:

$$F(x) = \sum_{i=1}^N \delta(x - x_i) * G_{\sigma_i}(x)$$

$$G_{\sigma}(x) = \frac{1}{2\pi\sigma^2} e^{-\|x\|^2/(2\sigma^2)}$$

- **Broj osoba** = $\sum$ vrednosti piksela mape gustine
- Fiksna $\sigma = 15$ (kontrolisano poređenje) vs. adaptivna (u daljem radu)
- Prednost: uči distribuciju gužve, robustno na okluzije



Slika $\rightarrow$ anotacije $\rightarrow$ mapa gustine

Diskretni Gausov kernel:

$$\frac{1}{273} \begin{bmatrix} 1 & 4 & 7 & 4 & 1 \\ 4 & 16 & 26 & 16 & 4 \\ 7 & 26 & 41 & 26 & 7 \\ 4 & 16 & 26 & 16 & 4 \\ 1 & 4 & 7 & 4 & 1 \end{bmatrix}$$

težine oko tačke glave, $\sigma \approx 1.05$; zbir težina
 $= \frac{273}{273} = 1$ — svaka glava doda tačno 1 osobu

Arhitektura: MCNN (Zhang et al., 2016)

- **Problem skale:** bliske glave $\sim 30 \times 30$ px, daleke $\sim 5 \times 5$ px — jedan filter ne pokriva obe
- **Rešenje:** tri paralelne grane, svaka specijalizovana za jednu skalu
- **Fuzija:** konkatencija kanala + 1×1 konv. uči gde da veruje kojoj grani (gusta gužva $\rightarrow$ sitni filteri)
- Učenje od nule (from scratch), bez pretreniranog backbone-a
- **Slabosti:** gubitak rezolucije kroz pooling ($\frac{H}{4}$); nema transfera znanja

Grana	Filteri	Kanali
Velika (bliske)	$9 \times 9, 7 \times 7$	$16 \rightarrow 32$
Srednja	$7 \times 7, 5 \times 5$	$20 \rightarrow 40$
Mala (daleke)	$5 \times 5, 3 \times 3$	$24 \rightarrow 48$

Svaka grana: conv $\rightarrow$ pool(2×2) $\rightarrow$ conv $\rightarrow$ pool(2×2)

Konkat. (120 kanala) $\rightarrow 1 \times 1 \Rightarrow$ mapa gustine
 $\frac{H}{4} \times \frac{W}{4}$

64K parametara

Arhitektura: CSRNet (Li et al., 2018)

- **Dilated konvolucija:** 3×3 kernel sa “rupama” $\Rightarrow$ receptivno polje 7×7 , i dalje samo 9 parametara (dilation=2)
- Bez poolinga u backendu $\Rightarrow$ rezolucija se ne gubi dalje
- **Frontend:** VGG16 pretreniran na ImageNet — transfer znanja iz opštih vizuelnih reprezentacija
- **Backend:** 6 dilated konv. trenirano od nule
- 16M parametara $\Rightarrow$ veliki kapacitet, ali rizik overfitting-a na 300 slika

Deo	Detalj
Frontend	VGG16 do conv4_3 ImageNet, 3 poolinga $\Rightarrow$ $\frac{H}{8}$
Backend	$6 \times$ Conv 3×3 , dilat. 2 $512 \rightarrow 256 \rightarrow 128 \rightarrow 64$
Izlaz	Conv $1 \times 1 \Rightarrow$ mapa gus- tine

Rezolucija pada samo $8 \times$ (3 poolinga), umesto
 $32 \times$ kod punog VGG16
16M parametara

Hipoteza: Duboka dilated arhitektura (CSRNet) trebala bi da nadmaši multi-column pristup (MCNN) na gustim scenama.

- **Dataset:** ShanghaiTech Part A
 - 300 trening slika, 182 test slike
 - Do 3000 ljudi po slici (visoka gustina)
- **Trening:**
 - Optimizator: SGD sa momentumom 0.95
 - Loss: MSE (pixel-wise) na mapi gustine
 - 50 epoha, batch size 4, seed 42
 - Bez augmentacije (kontrolisano poređenje modela)
- **Metrike:** MAE (Mean Absolute Error), RMSE (Root Mean Squared Error)
- **Konvencija:** Broj ljudi = integral mape gustine

Rezultati: Poređenje na test skupu


Model	Test MAE	Test RMSE	Parametri	Najbolja epoha
MCNN	315.23	429.16	64,385	50
CSRNet	217.13	342.66	16,263,489	34

Rezultat: CSRNet je značajno bolji:

- MAE 31% niži (bolji)
- RMSE 20% niži (manja varijansa greške)
- Potvrđena hipoteza o superiornosti dubokih dilated arhitektura

Rezultati: Dinamika treniranja

Training dynamics: MCNN vs CSRNet on ShanghaiTech Part A (50 epochs)



Slika: Krive greške tokom treniranja (train vs validation MAE)

Analiza:

- CSRNet (pretrained VGG): Brza konvergencija, ali **overfitting** posle epohe 34 (val MAE raste, train MAE opada)
- MCNN (from scratch): Sporija konvergencija, stabilno do kraja, ali na višem nivou greške

Analiza: Razlika u odnosu na originalne radove

Model	Naš rezultat		Originalni rezultat	
	MAE	RMSE	MAE	RMSE
MCNN	315	429	~110	~173
CSRNet	217	343	~68	~106

Razlozi odstupanja (sistematski, ne utiču na poređenje):

- Nema augmentacije podataka (random crops, flips)
- Nema learning rate scheduling
- Fiksna σ (umesto adaptivne)
- Manji broj epoha (50 vs. više stotina)

Važno: Relativni odnos je isti kao u literaturi (CSRNet < MCNN).

- **CSRNet superiorniji** od MCNN za brojanje u gustim gužvama na ShanghaiTech Part A
- Tradeoff kapaciteta i veličine skupa podataka:
 - Veliki model (CSRNet, 16M) brže uči ali overfituje na malom datasetu (300 slika)
 - Mali model (MCNN, 64K) sporiji ali stabilniji
- Validnost metodologije: Poređenje pod identičnim uslovima eliminiše uticaj pipeline-a
- **Budući rad:**
 - Augmentacija podataka (kritično za CSRNet)
 - Adaptivna σ za mapu gustine
 - Learning rate scheduling i duži trening

Hvala na pažnji!